

Trafik ve Enerji Kısıtlı Çoklu Ajan Ortamlarında Hibrit A*/Pekiştirmeli Öğrenme Tabanlı Akıllı Lojistik Simülasyonu

[OUSMAN MOUSSA MAHAMAT]

[Bursa Teknik Üniversitesi], Bilgisayar Mühendisliği Bölümü

Özet—Kentsel son-mil teslimat ağlarında kuryelerin verimliliği; trafik yoğunluğunun, taşıt enerji kısıtlarının ve çoklu ajan koordinasyonunun eşzamanlı biçimde yönetilmesine bağlıdır. Geleneksel tekil-ajan yol bulma demoları, bu üç boyutu birlikte ele almadığından gerçekçi lojistik senaryoları temsil etmekte yetersiz kalmaktadır. Bu çalışmada, 20×20 boyutlu ızgara-tabanlı bir şehir modeli üzerinde çalışan, trafik-ağırlıklı A* algoritması ile tablo tabanlı Q-öğrenme (Q-learning) yaklaşımını aynı arayüzde karşılaştırmalı biçimde sunan bir Akıllı Lojistik Simülatörü sistem düzeyinde incelenmiştir. Sistem; sınırlı batarya kapasiteli üç araç profili (motosiklet, bisiklet, araba), rastgele konumlanan trafik bölgeleri ve şarj istasyonları ile 1-3 ajanlı, claim (talep) tabanlı çıkışma önleme mekanizmasına sahip bir çoklu-kurye mimarisi içermektedir. A* algoritmasının trafik ağırlıklandırması altında Manhattan heuristiğinin admissibility (kabul edilebilirlik) özelliğinin teorik durumu formel olarak incelenmiş; Q-öğrenme ajanı için durum-aksiyon uzayı, ϵ -greedy keşif stratejisi ve zamansal-fark güncelleme kuralı tanımlanmıştır. Sistemden alınan örnek bir çalışma anına ait telemetri verileri (süre, mesafe, ödül, ceza, net kâr) üzerinden davranışsal bir değerlendirme yapılmıştır. Bulgular, deterministik planlamanın tutarlı ve hızlı yakınsayan rotalar ürettiğini, öğrenen yaklaşımın ise epizodlar ilerledikçe rota kalitesini kademeli olarak iyileştirdiğini; ancak her iki yaklaşımın da küresel optimizasyondan ziyade yerel (greedy) karar mekanizmalarına dayandığını göstermektedir.

Anahtar Kelimeler—A* Algoritması, Pekiştirmeli Öğrenme, Q-Öğrenme, Çoklu Ajan Sistemleri, Enerji Kısıtlı Rota Planlama, Lojistik Optimizasyonu.

I. GİRİŞ

Akıllı şehir kavramının temel bileşenlerinden biri, kaynak kısıtlı araçların dinamik kentsel ortamlarda verimli biçimde yönlendirilmesidir. Son-mil teslimat operasyonlarında kuryelerin trafik yoğunluğuna maruz kalması, hem operasyonel maliyeti hem de teslimat süresini doğrudan artırmaktadır. Öte yandan, elektrikli veya sınırlı enerjili taşıtların yaygınlaşması, rota planlamasına ek bir kısıt kümesi -- şarj istasyonu erişimi ve batarya yönetimi -- eklemiştir.

Klasik deterministik yol bulma algoritmaları (A*, Dijkstra), tam bilgiye sahip statik ortamlarda optimal veya optimale yakın çözümler üretebilse de, hücre başına maliyetin trafik yoğunluğuna göre değiştiği ortamlarda kullanılan heuristik fonksiyonların teorik garantileri zayıflayabilmektedir. Buna karşın pekiştirmeli öğrenme (RL) tabanlı yaklaşımlar, ortamı önceden tam olarak modellemeksizin, deneyim yoluyla bir politika öğrenerek stokastik ve dinamik ortamlara uyum sağlayabilmektedir.

Bu çalışmada sunulan Akıllı Lojistik Simülatörü, klasik A* planlamasını, tablo tabanlı Q-öğrenme ile aynı arayüz ve aynı ödül-ceza metrikleri üzerinden karşılaştırmalı biçimde değerlendirmeyi amaçlayan bir test platformudur. Çalışmanın katkıları şu şekilde özetlenebilir: (i) trafik-ağırlıklı A*

algoritmasının admissibility özelliğinin formel incelemesi, (ii) çoklu ajan senaryosunda açgözlü-en-yakın-komşu ve claim tabanlı çıkışma önleme mekanizmasının tasarımı, (iii) enerji kısıtlı rota planlamasını temsil eden batarya/şarj modelinin A* ve RL modlarına entegrasyonu, (iv) sistem üzerinden alınan gerçek telemetri verileriyle davranışsal bir değerlendirme.

II. İLGİLİ LİTERATÜR

A. Geleneksel Yol Bulma ve Sezgisel Algoritmalar

A* algoritması, Hart, Nilsson ve Raphael [2] tarafından önerilmiş; $f(n) = g(n) + h(n)$ değerlendirme fonksiyonu ile tam (complete) ve heuristik açıdan bilgilendirilmiş bir arama yöntemi olarak literatüre girmiştir. Algoritmanın optimal çözüm garantisi, heuristik fonksiyonun admissible olması, yani gerçek kalan maliyeti hiçbir zaman aşmaması koşuluna dayanır. Değişken hücre maliyetli (örn. trafik ağırlıklı) ortamlarda sabit bir heuristiğin bu koşulu koruyup korumadığı, uygulamalı çalışmalarda sıklıkla göz ardı edilen fakat teorik açıdan kritik bir noktadır.

B. Pekiştirmeli Öğrenme ve Çoklu Ajan Koordinasyonu

Sutton ve Barto [1] tarafından sistematikleştirilen pekiştirmeli öğrenme çerçevesi, bir ajanın beklenen kümülatif ödülü maksimize edecek bir politika öğrenmesini tanımlar. Watkins ve Dayan'ın [3] önerdiği Q-öğrenme, model bilgisi gerektirmeyen (model-free) bir zamansal-fark yöntemi olarak, durum-aksiyon değer fonksiyonunu iteratif biçimde günceller. Çoklu ajan yol planlaması (MAPF) literatüründe Sharon vd. [5], küresel optimal çözümler üreten Conflict-Based Search (CBS) yöntemini önermiş; buna karşın öncelik tabanlı planlama ve kilitleme (claim) mekanizmaları, hesaplama maliyetini düşürmek pahasına yerel-optimal çözümler üretmektedir. Görev atama tarafında, çoklu ajanın çoklu hedefe en düşük toplam maliyetle eşlenmesi problemi Kuhn'un [4] Macar Algoritması ile polinom zamanda çözülebilmektedir.

C. Enerji Kısıtlı Araç Rotalama

Elektrikli/sınırlı enerjili araç filolarının yaygınlaşmasıyla birlikte, Toth ve Vigo [7] tarafından ele alınan klasik Araç Rotalama Problemi (VRP), şarj istasyonu konumlandırma ve şarj molası zamanlaması gibi ek kısıtlarla genişletilmiştir (E-VRP). Bu çalışmada incelenen sistem, söz konusu literatürdeki temel unsurları (batarya tüketimi, şarj istasyonu, enerji tükenmesi durumunda görev devri) basitleştirilmiş fakat kavramsal olarak tutarlı biçimde yeniden üretmektedir.

III. SİSTEM MODELİ VE ORTAM FORMÜLASYONU

Ortam, sabit boyutlu $G = (V, E)$ ızgara grafiği olarak modellenmiştir; $|V| = 20 \times 20 = 400$ hücre bulunur ve her hücre {yol, bina} kümesinden bir tip alır.

A. Çevre (Environment) Modellemesi

Başlangıçta 15 adet rastgele bina bloğu (1-3 hücre genişlik $\times$ 1-2 hücre yükseklik) ızgaraya yerleştirilerek geçirilemez engeller oluşturulur. Yol hücrelerinin 16 tanesi rastgele trafik bölgesi olarak işaretlenir; her trafik hücresine $w_c \in \{2.0, 2.5, 3.0\}$ kümesinden bir maliyet/tüketim çarpanı atanır. Yol üzerinde rastgele 3 adet şarj istasyonu konumlandırılır; bir ajan bu hücreye girdiğinde bataryası, kapasiteyi aşmamak koşuluyla +9 birim artırılır. Teslimat hedefleri, sekiz farklı lokasyon tipinden (AVM, Teknopark, Hastane, Liman Deposu, Üniversite, Market, Havalimanı, Sanayi Bölgesi) oluşan bir havuzdan rastgele seçilir; her sıfırlamada 6 hedef boş hücrelere yerleştirilir.

B. Araç ve Batarya Modeli

Sistem, her biri farklı bir hız-tüketim dengesi taşıyan üç araç profili sunar (Tablo II). Bir ajanın t adımındaki batarya güncellemesi:

$$B(t+1) = B(t) - d_v \cdot w_c(t) \quad (1)$$

Burada d_v , araç profiline özgü sabit tüketim katsayısını; $w_c(t)$, ajanın t anında bulunduğu hücrenin trafik çarpanını (trafik hücresi değilse 1.0) temsil eder. Batarya sıfıra ulaştığında ajan stranded (mahsur) durumuna geçer ve üzerine atanmış hedef diğer ajanlar tarafından devralınabilir hâle getirilir; bu da sistemde dolaylı bir hata toleransı sağlar.

C. Ajan Durumu ve Çoklu Ajan Temsili

Sistemde 1 ile 3 arasında eşzamanlı çalışan ajan desteklenir. Her ajan; konum, planlı yol, batarya seviyesi, araç profili, durum (idle/moving/to_end/done/stranded) ve mevcut hedef bilgilerini tutan bir kayıt olarak temsil edilir. Genel simülasyon seviyesinde toplam adım sayısı, geçen süre, kümülatif ödül ve ceza izlenmektedir.

IV. ALGORİTMALAR VE OPTİMİZASYON STRATEJİLERİ

A. Trafik Ağırlıklı A* Algoritması

Deterministik planlama modunda her ajan, klasik A* değerlendirme fonksiyonunun trafik-ağırlıklı bir genişletmesiyle hedefe olan yolunu hesaplar:

$$f(n) = g(n) + h(n) \quad (2)$$

Komşu geçiş maliyeti trafik çarpanıyla ağırlıklandırılır:

$$g(n') = g(n) + w_c(n'), \quad w_c \in \{1.0, 2.0, 2.5, 3.0\} \quad (3)$$

$h(n)$ Manhattan mesafesi olarak tanımlanmıştır. Birim maliyetli bir ızgarada bu heuristik admissible'dir; ancak trafik hücrelerinde gerçek geçiş maliyeti 2-3 katına çıktığından, sabit kalan Manhattan heuristiği artık gerçek maliyetin geçerli bir alt sınırı olmayabilir. Bu durum algoritmanın tamliğini (completeness) etkilemez, fakat 'garantili optimal çözüm' iddiasını trafik aktifken teorik olarak zayıflatır. Admissibility'nin korunması için heuristiğin ortamdaki minimum hücre maliyetiyle ölçeklendirilmesi ($h' = w_{min} \cdot$ Manhattan) önerilmektedir.

B. Q-Öğrenme Tabanlı Pekiştirmeli Öğrenme

Alternatif modda her ajan, durum uzayı $s = (\text{pos}, \text{hedef})$ ve dört yönlü aksiyon uzayı $A = \{\text{yukarı}, \text{aşağı}, \text{sol}, \text{sağ}\}$ üzerinde çalışan tablo tabanlı bir Q-öğrenme politikasıyla hareket eder. Keşif oranı epizod sayısına göre azalan bir ϵ -greedy stratejisiyle kontrol edilir:

$$\epsilon(\text{episode}) = \max(0.05, 0.6 - 0.03 \cdot \text{episode}) \quad (4)$$

Q-değeri güncellemesi, öğrenme oranı $\alpha = 0.3$ ve indirim katsayısı $\gamma = 0.9$ ile klasik zamansal-fark kuralına göre yapılır:

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)] \quad (5)$$

Q-tablosu oturum boyunca kalıcıdır; ortam yeniden üretilse dahi biriken deneyim korunur ve epizodlar ilerledikçe rota kalitesi kademeli olarak iyileşir.

C. Ödül Şekillendirme ve Ceza Fonksiyonu

Ödül sinyali, hedefe ulaşma anında sabit bir bonus ile ara adımlarda hedefe yaklaşma/uzaklaşmaya bağlı yoğun (dense) bir bileşenin toplamından oluşur; bu, Ng vd. [6] tarafından önerilen potansiyele dayalı ödül şekillendirmenin basitleştirilmiş bir uygulamasıdır:

$$r(t) = 10 [\text{hedef}] \text{ veya } (0.3 [\text{yakınlaştı}] / -0.6 [\text{uzaklaştı}]) - \text{ceza_trafik}(t) \quad (6)$$

Bir hedefe ulaşıldığında kazanılan bonus, geçen süreye bağlı azalan bir fonksiyondur:

$$\text{bonus} = \max(50, 300 - 2 \cdot \text{elapsed}_s) \quad (7)$$

Her adımda hız seviyesine ve trafik durumuna bağlı bir ceza işlenir:

$$\text{ceza}(t) = \text{pen_hız} \cdot w_c(t), \quad \text{pen_hız} \in \{0.4, 0.8, 1.4\} \quad (8)$$

Net performans göstergesi, Denklem (9) ile tanımlanır:

$$\text{NetKâr} = \text{Ödül} - \text{Ceza} \quad (9)$$

D. Çoklu Ajan Koordinasyonu: Açgözlü Atama ve Claim Mekanizması

Hedef ataması merkezi bir optimizasyon algoritması yerine, her ajanın bağımsız çalıştırdığı açgözlü-en-yakın-komşu kuralıyla gerçekleştirilir:

$$\text{hedef}^* = \text{argmin}_{\{t \in U\}} \text{dist}(\text{pos}, \text{pos}_t) \quad (10)$$

Burada U , henüz ziyaret edilmemiş ve başka bir ajan tarafından talep edilmemiş hedefler kümesidir. Bir hedef talep edildiğinde (claimed_by), aynı hedefe başka bir ajanın yönlendirilmesi engellenir; bu, MAPF literatüründeki çakışma önleme problemine düşük maliyetli bir çözüm sunar, fakat toplam kat edilen mesafeyi minimize eden küresel bir atamayı (örn. Macar Algoritması [4]) garanti etmez. Bir ajan mahsur kaldığında talebi bırakılır ve hedef yeniden açık hâle gelerek kendiliğinden yeniden dengeleme sağlanır.

V. SİMÜLASYON VE BULGULAR

A. Deney Ortamı ve Parametreler

Simülasyon, Tablo I'de özetlenen parametrelerle Python ve Pygame ortamında çalıştırılmıştır.

Tablo I
SİMÜLASYON ORTAMI PARAMETRELERİ

Parametre	Değer
Izgara Boyutu	20 $\times$ 20
Bina Blok Sayısı	15
Trafik Hücre Sayısı	16
Trafik Çarpanı	2.0/2.5/3.0 $\times$
Şarj İstasyonu Sayısı	3


Şarj Miktarı	+9 birim
Batarya Kapasitesi	60/100/160
Ajan Sayısı	1 – 3
Hedef Sayısı (epizod)	6
Q-Öğrenme α / γ	0.3 / 0.9

Tablo II
ARAÇ PROFİLLERİNİN HIZ VE TÜKETİM KATSAYILARI

Araç	Hız	Tüketim
Motosiklet	1.0×	1.0×
Bisiklet	0.65×	0.5×
Araba	1.6×	1.8×

B. Arayüz ve Örnek Çalışma Anı

Geliştirilen arayüz, ızgara tabanlı harita görünümü ile gerçek zamanlı kontrol ve telemetri panelinden oluşur (Şekil 1). Örnek bir çalışma anında sistem RL modunda, 3 ajan ve 'Araba' araç profiliyle çalıştırılmıştır; telemetri paneli 39 saniye geçtiğini, toplam 39 adım kat edildiğini, kümülatif ödülün henüz +0, kümülatif cezanın ise -36 puana ulaştığını ve dolayısıyla Net Kâr göstergesinin -36 puan olduğunu bildirmektedir.



Şekil 1. Geliştirilen simülasyon arayüzü. Ajanlar RL modunda mevcut hedefe (Liman Deposu) yönelirken gerçek zamanlı telemetri paneli sistem durumunu göstermektedir.

Negatif net kârın epizod başında gözlenmesi beklenen bir durumdur; Denklem (7)-(8)'de tanımlanan ödül-ceza yapısı gereği ceza bileşeni her adımda işlerken, ödül bileşeni yalnızca bir hedefe ulaşıldığında devreye girmekte, bu da sistemde geçici bir 'ödül açığı' dönemi yaratmaktadır.

C. Davranışsal Analiz: A* ve RL Karşılaştırması

A* modu deterministik olduğundan aynı harita konfigürasyonu için tutarlı ve genellikle daha hızlı yakınsayan rotalar üretir. RL modu ise düşük epizod sayısında (yüksek ϵ) verimsiz bir keşif sergiler; Q-tablosunun oturum boyunca kalıcı olması sayesinde epizodlar ilerledikçe rota kalitesi kademeli olarak iyileşir. Düşük tüketimli bisiklet profili daha az şarj olması gerektirir fakat toplam epizod süresini uzatır; yüksek hızlı fakat yüksek tüketimli araba profili ise daha sık şarj gereksinimi doğurarak dolaylı bir zaman maliyeti yaratabilir. Çoklu ajan senaryosunda hedeflerin claim mekanizmasıyla otomatik paylaşıldığı, fakat bu paylaşımın küresel optimizasyona değil,

her ajanın kendi açısından açgözlü kararına dayandığı gözlemlenmiştir; Şekil 1'deki örnekte üç ajanın da başlangıçta aynı hedefe (Liman Deposu) yönlendirilmiş olması, açgözlü-en-yakın-komşu kuralının başlangıç konumlarına duyarlı olduğunu göstermektedir.

D. Sınırlılıklar

Trafik aktifken Manhattan heuristiği admissible değildir (bkz. Bölüm IV-A); hedef ataması küresel değil açgözlüdür; RL ajanının durum uzayı (pos, hedef) ile sınırlı olduğundan trafik ve batarya bilgisini doğrudan gözlemleyemez; trafik ve şarj istasyonu konumları epizod boyunca statiktir; rotalar yol yumuşatma uygulanmadığından 'merdiven' biçiminde ilerler.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, klasik A* yol planlaması ile tablo tabanlı Q-öğrenme, trafik yoğunluğu, sınırlı batarya kapasitesi ve çoklu ajan koordinasyonu kısıtları altında aynı arayüzde karşılaştırmalı biçimde değerlendirilmiştir. Trafik ağırlıklandırmasının A*'ın Manhattan heuristiğinin admissibility özelliğini formel olarak zayıflatığı, buna karşın algoritmanın tamlığını koruduğu gösterilmiştir. Sistemden alınan örnek telemetri verileri, ödül-ceza formülasyonunun epizod başında beklenen bir açık yarattığını ve çoklu ajan koordinasyonunun yerel açgözlü kararlara dayandığını doğrulamıştır.

Gelecek çalışmalarda; RL durum uzayının batarya ve trafik farkındalığıyla genişletilmesi (gerekirse Derin Q-Ağları ile), görev atamasının Macar Algoritması ile küresel biçimde optimize edilmesi, trafiğin dinamik hâle getirilerek D* Lite tabanlı yeniden planlama yapılması ve heuristiğin admissibility'yi koruyacak biçimde ölçeklendirilmesi planlanmaktadır. Ayrıca sistemin çoklu tohum (seed) ve çoklu koşu ile istatistiksel olarak nicel biçimde değerlendirilmesi, A* ile RL politikalarının toplam mesafe, ortalama teslimat süresi ve net kâr metrikleri üzerinden sistematik bir karşılaştırmasının yapılması hedeflenmektedir.

KAYNAKLAR

- [1] R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction, 2nd ed., Cambridge, MA, USA: MIT Press, 2018.
- [2] P. E. Hart, N. J. Nilsson, and B. Raphael, "A formal basis for the heuristic determination of minimum cost paths," IEEE Trans. Syst. Sci. Cybern., vol. 4, no. 2, pp. 100–107, 1968.
- [3] C. J. C. H. Watkins and P. Dayan, "Q-learning," Machine Learning, vol. 8, pp. 279–292, 1992.
- [4] H. W. Kuhn, "The Hungarian method for the assignment problem," Naval Research Logistics Quarterly, vol. 2, no. 1–2, pp. 83–97, 1955.
- [5] G. Sharon, R. Stern, A. Felner, and N. R. Sturtevant, "Conflict-based search for optimal multi-agent pathfinding," Artificial Intelligence, vol. 219, pp. 40–66, 2015.
- [6] A. Y. Ng, D. Harada, and S. Russell, "Policy invariance under reward transformations: Theory and application to reward shaping," in Proc. 16th Int. Conf. Mach. Learn. (ICML), 1999, pp. 278–287.
- [7] P. Toth and D. Vigo, Vehicle Routing: Problems, Methods, and Applications, 2nd ed., Philadelphia, PA, USA: SIAM, 2014.
- [8] V. Mnih et al., "Human-level control through deep reinforcement learning," Nature, vol. 518, no. 7540, pp. 529–533, 2015.